

Métodos Numéricos Aplicados a Finanças — Turma 2025

Todas as aulas

Prof. Frega

11/03/2025

Sumário

AULA 1	1
1 Introdução	3
1.1 Objetivos	3
1.1.1 Objetivo Geral	3
1.1.2 Objetivo Específico	3
1.1.2.1 Subsubseção	3
1.1.2.1.1 Parágrafo	3
1.1.2.1.1.1 Subparágrafo	3
2 Referencial teórico-empírico	5
3 Metodologia	7
4 Análise de dados e discussão dos resultados	9
5 Dados do Principles of Econometrics	13
5.1 Pacote PoEdata_0.1.0.tar.gz	13
5.2 Pequeno exemplo de programação em R	14
AULA 2	25
6 Regressão linear simples	27
6.1 Modelo geral	27
6.2 Example: Food Expenditure versus Income	29
6.3 Estimating a Linear Regression	30
6.4 Prediction with the Linear Regression Model	32
6.5 Repeated Samples to Assess Regression Coefficients	32
6.6 Estimated Variances and Covariance of Regression Coefficients	33
6.7 Non-Linear Relationships	33
6.7.1 Verificando a variável dependente	35
6.7.2 Transformação logarítmica	36
6.8 Using Indicator Variables in a Regression	37
6.9 Monte Carlo	38
7 Chapter 3 Interval Estimation and Hypothesis Testing	39
7.1 Example: Confidence Intervals in the food Model	39
7.2 Bootstrap	39
8 Adendo - ler dados do EXCEL	43
9 Adendo — Regressão OLS em Python	45

AULA 1

Capítulo 1

Introdução

Aqui começamos a escrever a introdução do nosso material.

Aqui continuamos

A seguir vamos colocando outros itens tipográficos

1.1 Objetivos

1.1.1 Objetivo Geral

1.1.2 Objetivo Específico

1.1.2.1 Subsubseção

1.1.2.1.1 Parágrafo

1.1.2.1.1.1 Subparágrafo Subsubparágrafo

Um subsubparágrafo é aceito pelo *markdown* mas não é definido tipograficamente. Normalmente usamos só até o nível 6, que é o subparágrafo.

Capítulo 2

Referencial teórico-empírico

Capítulo 3

Metodologia

Escrevendo uma equação

\$\$

$y = ax^2 + bx + c$

\$\$

$$y = ax^2 + bx + c$$

Capítulo 4


Análise de dados e discussão dos resultados

```
2 + 2
```


```
## [1] 4  
set.seed(1)  
.x <- rnorm(10000)  
head(.x, 10)
```

```
## [1] -0.6264538  0.1836433 -0.8356286  1.5952808  0.3295078 -0.8204684  
## [7]  0.4874291  0.7383247  0.5757814 -0.3053884  
tail(.x, 10)
```

```
## [1]  1.04776175 -0.02428861 -0.47787499 -0.02971747  0.20966546  0.95950757  
## [7]  0.43660362  0.49936656  0.89397983  0.25738706  
hist(.x, freq = FALSE, col = "yellow", border = "black")
```

Histogram of .x

```
hist(.x, freq = FALSE, col = "lightyellow", border = "gray")  
curve(dnorm(x, mean(.x), sd(.x)), xlim = c(min(.x), max(.x)),  
      add = TRUE, col = "#4040FFC0", lwd = 2.5)
```

Histogram of .x

1/2

```
## [1] 0.5
```


Capítulo 5

Dados do Principles of Econometrics

5.1 Pacote PoEdata_0.1.0.tar.gz

Uma vez instalado o pacote PoEdata_0.1.0.tar.gz

```
library(PoEdata)
```

```
library(printr)
```

```
## Registered S3 method overwritten by 'printr':
```

```
##   method          from
```

```
##   knit_print.data.frame rmarkdown
```

```
data(mroz)
```

```
head(mroz[, 1:5])
```

taxableinc	federaltax	hsiblings	hfathereduc	hmothereduc
12200	1494	1	14	16
18000	2615	8	7	3
24000	3957	4	7	10
16400	2279	6	7	12
10000	1063	3	7	7
6295	370	8	7	7

```
tail(mroz[, 1:5])
```

	taxableinc	federaltax	hsiblings	hfathereduc	hmothereduc
748	16100	1825	0	7	12
749	32000	4701	8	12	7
750	18500	2720	4	12	12
751	13000	1642	6	7	12
752	17200	2447	2	7	10
753	18700	2327	4	10	7

5.2 Pequeno exemplo de programação em R

```

library(DescTools)
plotSquare = function(deltay = 1.5, deltax = abs(deltay/Asp()),
  xbase = 12, ybase = 3, col = "#FF808040") {
  polygon(c(0, deltax, deltax, 0, 0) + xbase, c(0, 0, deltax,
    deltax, 0) + ybase, col = col)
}

plotRegressao = function(modelo1 = modelo1, horas = horas, nota = nota,
  sequencia = 5, sub = NULL) {
  # desenho os pontos observados
  plot(horas, nota, pch = 20, col = "darkgray", xlim = c(0,
    14), ylim = c(0, 100), axes = FALSE, sub = "Regressão linear simples",
    xlab = "Horas de estudo", ylab = "Nota na avaliação",
    main = sub)
  # desenho os eixos no (0, 0)
  axis(1, pos = 0)
  axis(2, pos = 0)
  # traça a linha do modelo1 em azul
  if (sequencia > 1)
    abline(modelo1, col = "blue")
  # calcula os pontos sobre a reta
  estimados <- predict(modelo1, horas = horas)
  # desenha os pontos sobre a reta
  if (sequencia > 2)
    points(horas, estimados, pch = 20, col = "blue")
  # desenha as barras de erro (y - ychapêu) e dá nome aos
  # pontos
  delta = 0.3
  if (sequencia > 3) {
    for (i in 1:length(horas)) {
      # desenha as barras de erro verticais
      lines(c(horas[i], horas[i]), c(estimados[i], nota[i]),
        col = "red")
      # desenha as linhas horizontais
      lines(c(horas[i] - delta, horas[i] + delta), c(estimados[i],
        estimados[i]), col = "red")
      lines(c(horas[i] - delta, horas[i] + delta), c(nota[i],
        nota[i]), col = "red")
      # coloca o nome do ponto acima ou abaixo dele
      # conforme a estética
      text(horas[i], nota[i], bquote(y[.(i)]), pos = ifelse(estimados[i] >
        nota[i], 1, 3))
    }
  }
  if (sequencia > 4) {
    for (i in 1:length(horas)) {
      deltax = horas[i] - estimados[i]
      deltax = abs(deltay/Asp())
      if (deltay > 0)
        deltax = -deltax
      plotSquare(xbase = horas[i], ybase = estimados[i],
        deltax = deltax, deltax = deltax)
    }
  }
}

```

```

}
text(8, 10, expression(min(Sigma(y[i] - bar(y[i]))^2)), cex = 1.2)
text(8, 15, "Mínimos quadrados ordinários minimiza o somatório dos quadrados dos erros",
      cex = 0.7)
}

# conjuntos de dados
nota <- c(40, 30, 60, 65, 70, 90)
horas <- c(2, 4, 6, 8, 10, 12)
# função lm (linear model) -> guarda em modelo1
lm(nota ~ horas) -> modelo1
plotRegressao(modelo1, horas, nota, 1, expression("Nuvem de pontos"))

```

Nuvem de pontos




Figura 5.1: Nota na avaliação *versus* horas de estudo

```
plotRegressao(modelo1, horas, nota, 2, expression(paste("Reta de regressão: ",
  nota == b[0] + b[1] * horas)))
```

Reta de regressão: $\text{nota} = b_0 + b_1 \text{horas}$

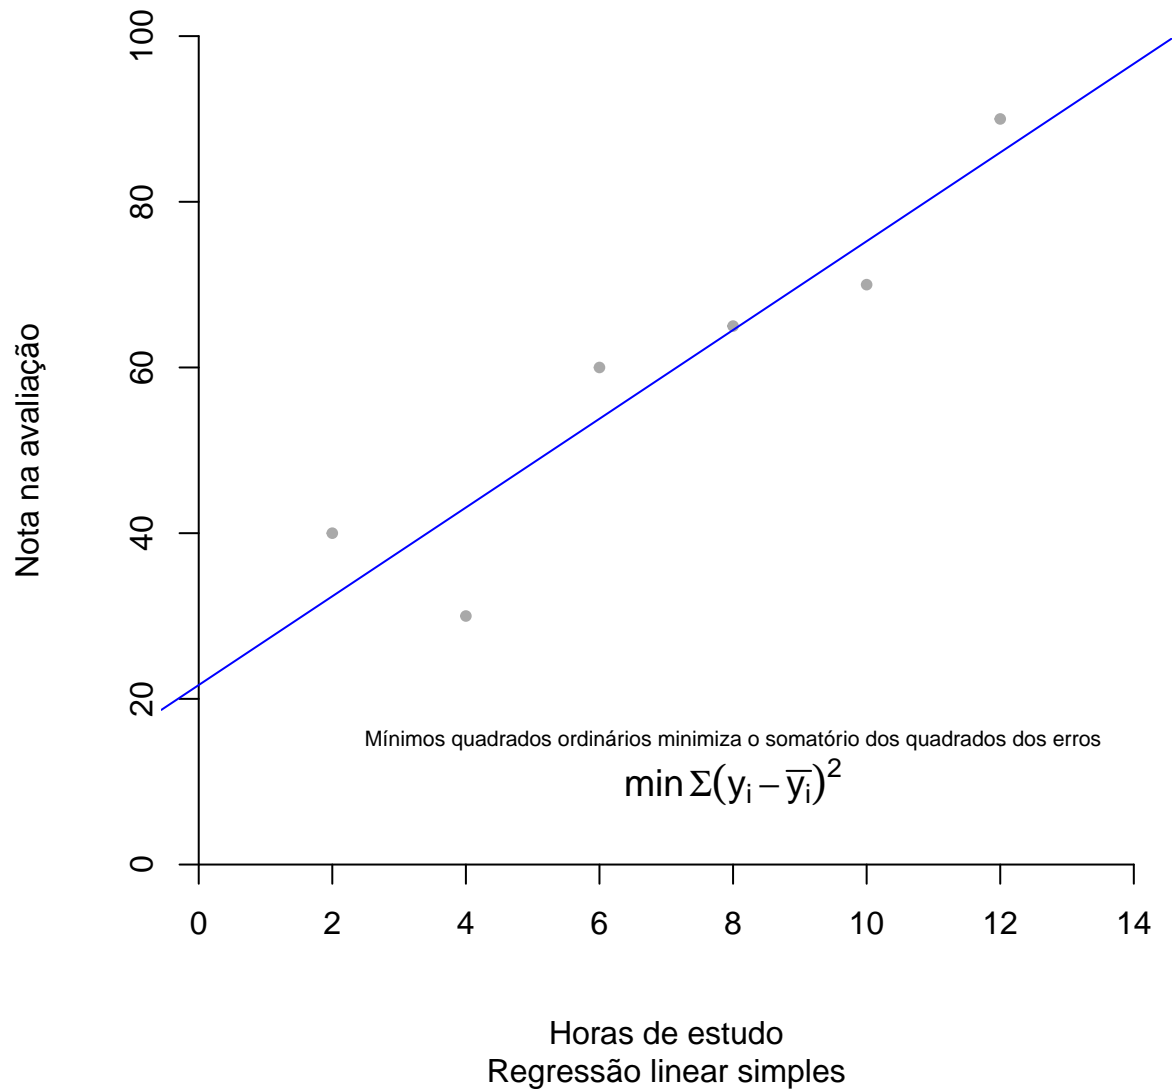


Figura 5.2: Nota na avaliação *versus* horas de estudo

```
plotRegressao(modelo1, horas, nota, 3, expression(paste("Reta de regressão com as estimativas ",
  hat(y))))
```

```
plotRegressao(modelo1, horas, nota, 4, expression(paste("Erros observados: ",
  y - hat(y))))
```

```
plotRegressao(modelo1, horas, nota, 5, expression(paste("Quadrados dos erros: ",
  (y - hat(y))^2)))
```

```
modelo1
```

```
##
```

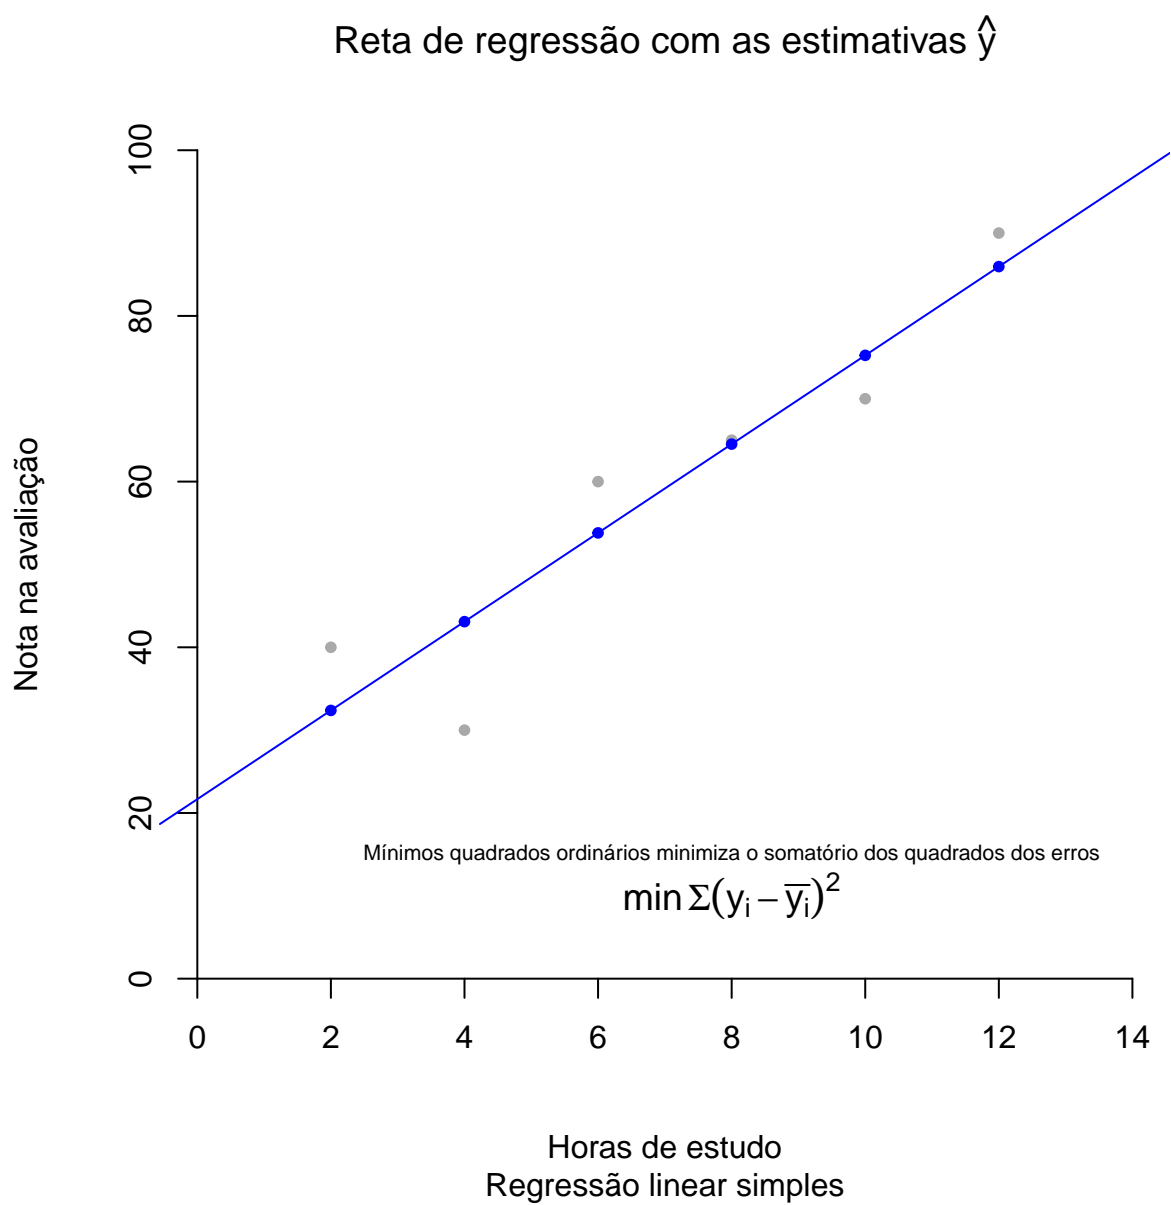


Figura 5.3: Nota na avaliação *versus* horas de estudo

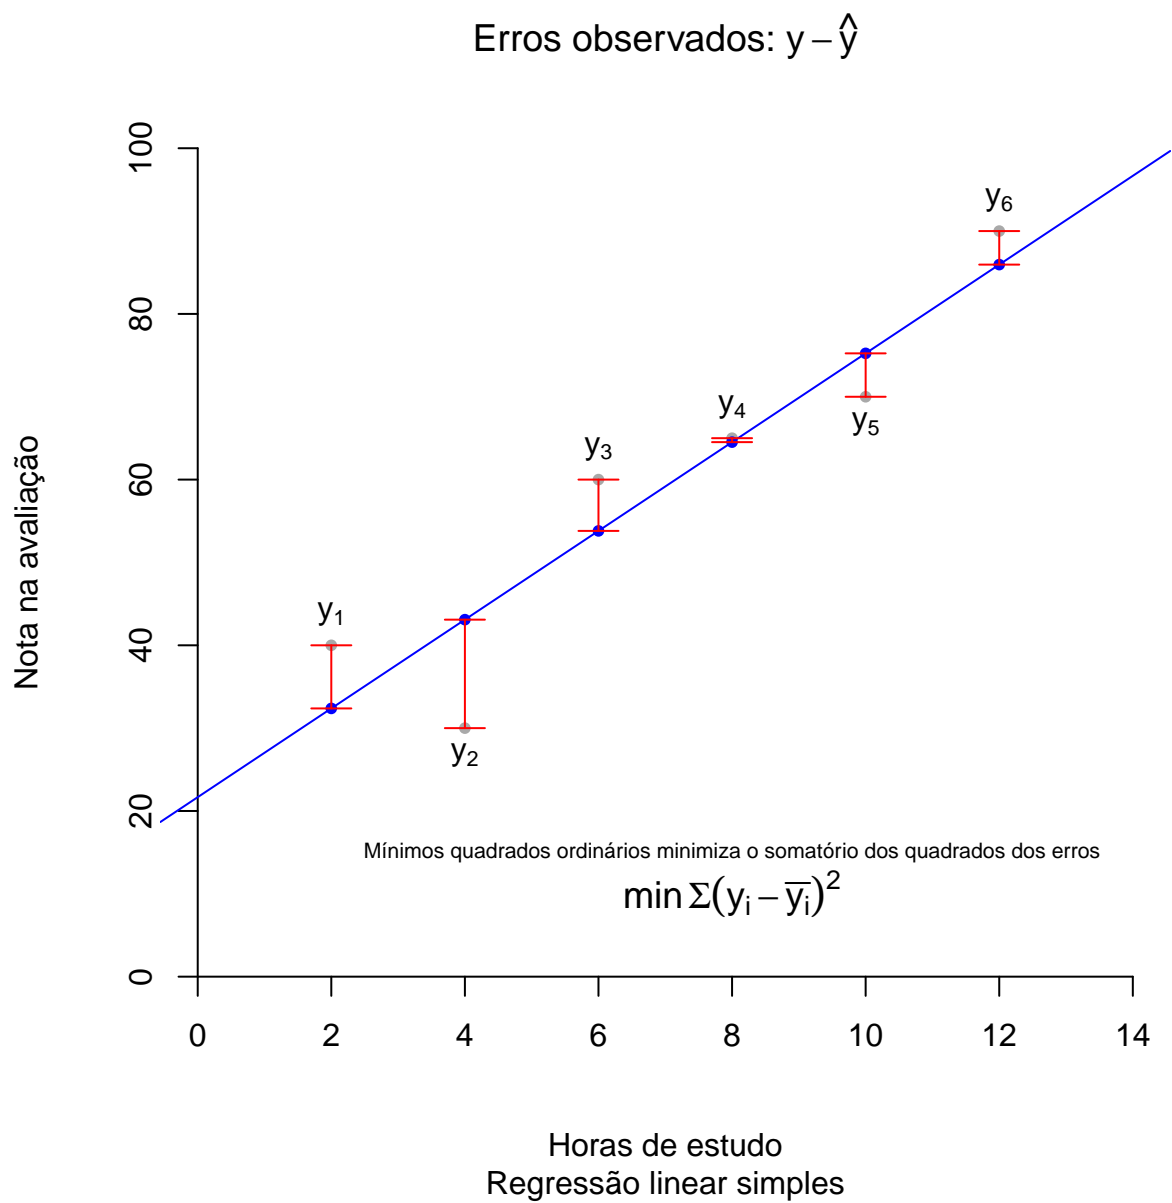


Figura 5.4: Nota na avaliação *versus* horas de estudo

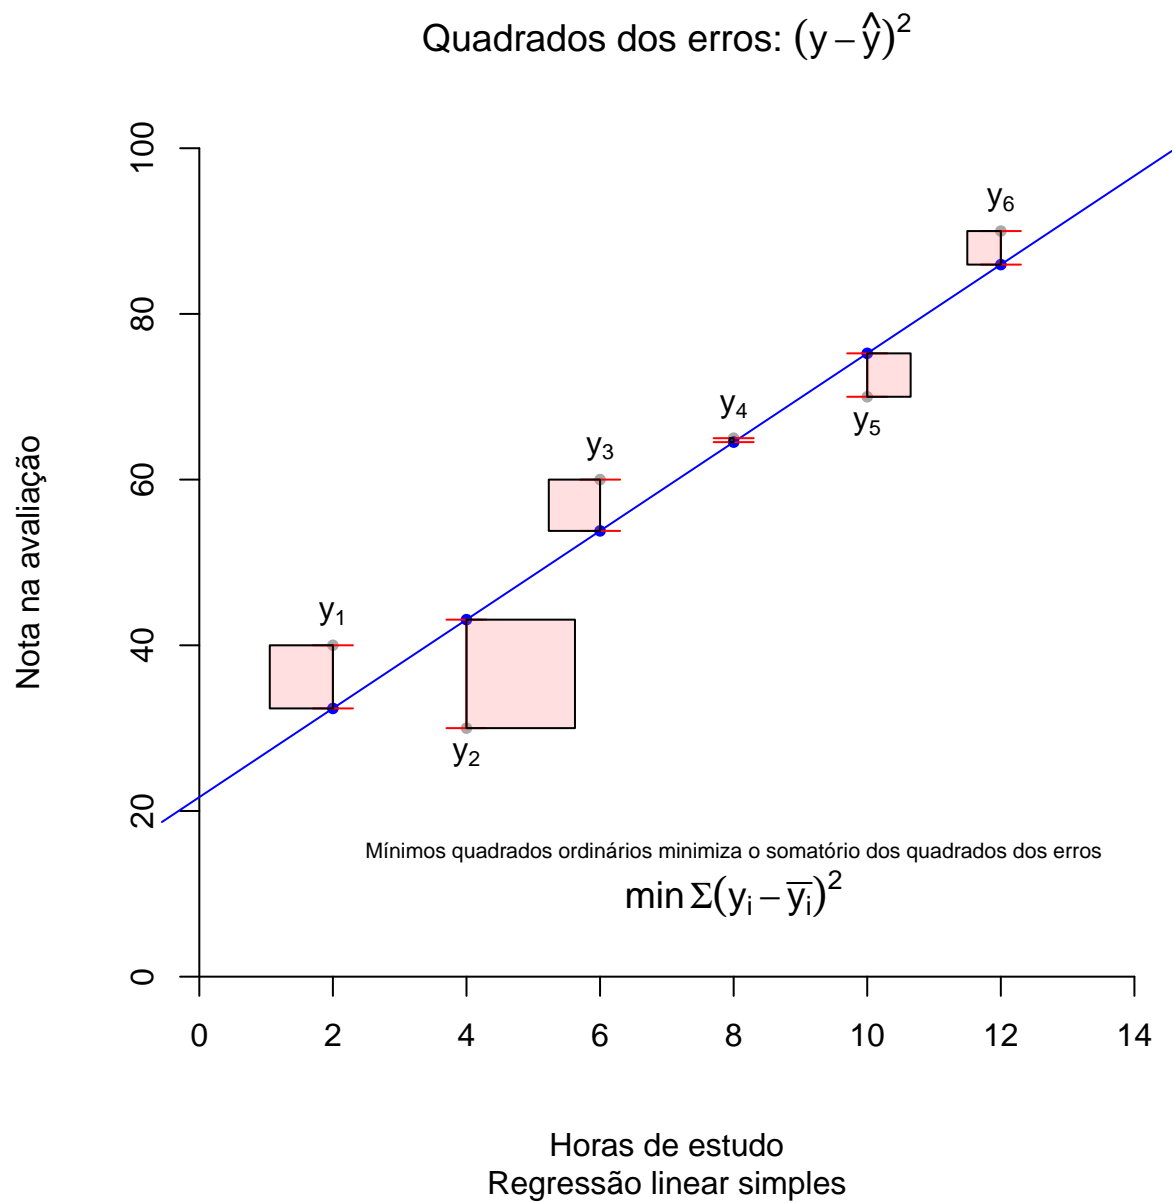


Figura 5.5: Nota na avaliação *versus* horas de estudo

```
## Call:
## lm(formula = nota ~ horas)
##
## Coefficients:
## (Intercept)      horas
##      21.667      5.357

modelo1$coefficients[1]

## (Intercept)
##      21.66667

modelo1$coefficients[2]

##      horas
## 5.357143

$$
\widehat{\text{nota}} = b_0 + b_1 \cdot \text{horas} = 21.6666667 + 5.3571429 \cdot \text{horas}
$$
```

$$\widehat{\text{nota}} = b_0 + b_1 \cdot \text{horas} = 21.6666667 + 5.3571429 \cdot \text{horas}$$

Diagnósticos do modelo

Estatística = testes de hipóteses

Uma hipótese pode ser rejeitada ou não

Existe um valor calculado para cada teste que se chama p.value (p-valor) para o qual existe um valor crítico, normalmente tomado como 0,05 (ou 5%) que chamamos de significância do teste.

Todo teste tem uma hipótese nula (H_0), se o p-valor for menor que o limite, rejeita-se H_0 , se for igual ou maior, aceita-se H_0 .

H_0 do teste F: não há relação entre as variáveis.

H_0 do teste t: o coeficiente associado é igual a zero.

```
summary(nota)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
30	45	62.5	59.16667	68.75	90

```
summary(horas)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
2	4.5	7	7	9.5	12

```
summary(.x)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
-3.6713	-0.6733944	-0.0159288	-0.006537	0.6776605	3.810277



```
summary(modelo1)
```

```
##
## Call:
## lm(formula = nota ~ horas)
##
## Residuals:
##      1      2      3      4      5      6
## 7.6190 -13.0952  6.1905  0.4762 -5.2381  4.0476
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  21.667      8.221   2.636  0.0578 .
## horas        5.357      1.055   5.076  0.0071 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 8.83 on 4 degrees of freedom
## Multiple R-squared:  0.8656, Adjusted R-squared:  0.832
## F-statistic: 25.76 on 1 and 4 DF, p-value: 0.007102
```


R^2 é a porção de variação da nota que é explicada pelas horas.

Ou seja, aproximadamente 83% da variação da nota é explicada pelas horas de estudo.

```
x = 1:6 * 10
y = 1:6
plot(x, y)
plotSquare(xbase = 20, ybase = 2, deltax = 0.5)
plotSquare(xbase = 30, ybase = 3, deltax = 1.5, col = "#8080FF40")
plotSquare(xbase = 40, ybase = 4, deltax = -2.5, col = "#80FF8040")
plotSquare(xbase = 50, ybase = 5, deltax = -1.5, col = "#FFFF8040")
abline(c(0, 0.1), col = "darkgray")
```



```
f = function(x) (x^3 + 8)/(x^4 - 16)
x = seq(-3, -1.0000001, length.out = 100)
y = f(x)
plot(x, y, type = "l")
abline(v = -2, h = -3/8, col = "lightblue")
text(-2.75, -0.4, expression(y == lim(frac(x^3 + 8, x^4 - 16),
  x %>% -2)))
text(-1.75, -0.35, expression(y(-2) == "?"))
```



```
f(-2.000000001)
```

```
## [1] -0.375
```

```
-3/8
```

```
## [1] -0.375
```

```
plot.new()
plot.window(c(0, 4), c(15, 1))
text(1, 1, "universal", adj = 0)
text(2.5, 1, "\\042")
text(3, 1, expression(symbol("\\")))
text(1, 2, "existential", adj = 0)
text(2.5, 2, "\\044")
text(3, 2, expression(symbol("$")))
text(1, 3, "suchthat", adj = 0)
text(2.5, 3, "\\047")
text(3, 3, expression(symbol("'")))
text(1, 4, "therefore", adj = 0)
text(2.5, 4, "\\134")
text(3, 4, expression(symbol("\\\\")))
text(1, 5, "perpendicular", adj = 0)
text(2.5, 5, "\\136")
text(3, 5, expression(symbol("^")))
```

```

text(1, 6, "circlemultiply", adj = 0)
text(2.5, 6, "\\304")
text(3, 6, expression(symbol("\\xc4")))
text(1, 7, "circleplus", adj = 0)
text(2.5, 7, "\\305")
text(3, 7, expression(symbol("\\xc5")))
text(1, 8, "emptyset", adj = 0)
text(2.5, 8, "\\306")
text(3, 8, expression(symbol("\\xc6")))
text(1, 9, "angle", adj = 0)
text(2.5, 9, "\\320")
text(3, 9, expression(symbol("\\xd0")))
text(1, 10, "leftangle", adj = 0)
text(2.5, 10, "\\341")
text(3, 10, expression(symbol("\\xe1")))
text(1, 11, "rightangle", adj = 0)
text(2.5, 11, "\\361")
text(3, 11, expression(symbol("\\xf1")))

```

universal	\042	∀
existential	\044	∃
suchthat	\047	∋
therefore	\134	∴
perpendicular	\136	⊥
circlemultiply	\304	⊗
circleplus	\305	⊕
emptyset	\306	∅
angle	\320	∠
leftangle	\341	⟨
rightangle	\361	⟩


AULA 2

```
library(magrittr)
```



Capítulo 6

Regressão linear simples

```
library(PoEdata)
data("cps_small")
plot(cps_small$educ, cps_small$wage, xlab = "education", ylab = "wage")
```




```
plot(cps_small$educ, cps_small$wage, xlab = "Educação", ylab = "Renda")
```



```
head(cps_small, 15)
```

wage	educ	exper	female	black	white	midwest	south	west
2.03	13	2	1	0	1	0	1	0
2.07	12	7	0	0	1	1	0	0
2.12	12	35	0	0	1	0	1	0
2.54	16	20	1	0	1	0	1	0
2.68	12	24	1	0	1	0	1	0
3.09	13	4	0	0	1	0	1	0
3.16	13	1	0	0	1	0	0	1
3.17	12	22	1	0	1	0	1	0
3.20	12	23	0	0	1	0	1	0
3.27	12	4	1	0	1	0	0	1
3.32	12	11	1	0	1	0	0	1
3.32	13	3	1	0	1	1	0	0
3.34	18	15	0	0	1	1	0	0
3.39	13	7	1	0	1	0	0	0
3.39	12	15	1	0	1	0	0	1

```
plot(cps_small$exper, cps_small$wage, col = "gray", pch = 20)
```


6.2 Example: Food Expenditure versus Income

```
library(PoEdata)
data(food)
head(food)
```


food_exp	income
115.22	3.69
135.98	4.39
119.34	4.75
114.96	6.03
187.05	12.47
243.92	12.98

```
# help(food)
```

```
data("food", package = "PoEdata")
plot(food$income, food$food_exp)
```



```
# Gráfico de dispersão ou scatter plot
plot(food$income, food$food_exp, ylim = c(0, max(food$food_exp)),
      xlim = c(0, max(food$income)), xlab = "weekly income in $100",
      ylab = "weekly food expenditure in $", type = "p")
```



6.3 Estimating a Linear Regression

$$food_exp = \beta_0 + \beta_1 income + e \quad \widehat{food_exp} = \beta_0 + \beta_1 income$$

```

library(PoEdata)
# roda a regressão
mod1 <- lm(formula = food_exp ~ income, data = food)
# olha os coeficientes
mod1$coefficients

## (Intercept)      income
##      83.41600      10.20964

# ou
coef(mod1)

## (Intercept)      income
##      83.41600      10.20964

# um por um
mod1$coefficients[1]

## (Intercept)
##      83.416

mod1$coefficients[2]

##      income
## 10.20964

# ou
(b1 <- coef(mod1)[[1]])

## [1] 83.416

(b2 <- coef(mod1)[[2]])

## [1] 10.20964

# mostra o resultado da regressão
smod1 <- summary(mod1)
smod1


##
## Call:
## lm(formula = food_exp ~ income, data = food)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -223.025  -50.816   -6.324    67.879   212.044
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   83.416      43.410   1.922  0.0622 .
## income        10.210       2.093   4.877 1.95e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 89.52 on 38 degrees of freedom
## Multiple R-squared:  0.385, Adjusted R-squared:  0.3688
## F-statistic: 23.79 on 1 and 38 DF, p-value: 1.946e-05
plot(food$income, food$food_exp, xlab = "Renda semanal em $100",
     ylab = "Despesa com comida em $", ylim = c(0, max(food$food_exp)),

```

```

xlim = c(0, max(food$income)), type = "p", col = "lightblue",
pch = 16, frame.plot = FALSE, axes = FALSE, main = "Despesa com comida versus renda")
axis(1, pos = 0)
axis(2, pos = 0)
# abline(b1,b2)
abline(mod1, col = "blue")
abline(h = b1, col = "darkgray", lty = 2)

```



6.4 Prediction with the Linear Regression Model

Qual a despesa com comida de um indivíduo que ganha \$2000 por semana?

$$\widehat{food_exp} = 83.416 + 10.210 \cdot income \quad \widehat{food_exp} = 83.416 + 10.210 \cdot 20$$

```
coef(mod1)[1] + coef(mod1)[2] * 20
```

```
## (Intercept)
##      287.6089
```

```
predict(mod1, data.frame(income = 20))
```

```
##           1
## 287.6089
```

6.5 Repeated Samples to Assess Regression Coefficients

Tecnicamente isso se chama *bootstrap* e trataremos depois.

6.6 Estimated Variances and Covariance of Regression Coefficients

Será útil mais tarde.

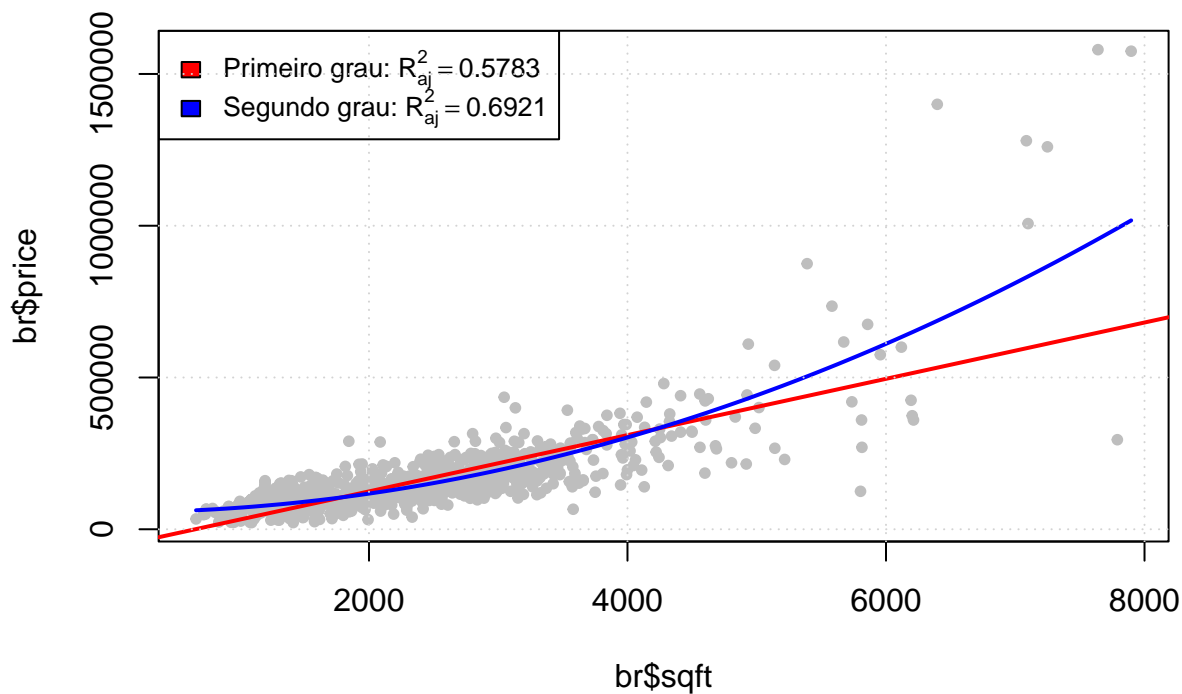
6.7 Non-Linear Relationships

```
library(PoEdata)
data(br)
# testando uma relação quadrática
mod3 <- lm(formula = price ~ I(sqft^2), data = br)
# versus uma do primeiro grau
mod3.a <- lm(formula = price ~ sqft, data = br)
(summary(mod3) -> s3)

##
## Call:
## lm(formula = price ~ I(sqft^2), data = br)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -696604  -23366       779    21869   713159
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  5.578e+04  2.890e+03   19.30  <2e-16 ***
## I(sqft^2)    1.542e-02  3.131e-04   49.25  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 68210 on 1078 degrees of freedom
## Multiple R-squared:  0.6923, Adjusted R-squared:  0.6921
## F-statistic: 2426 on 1 and 1078 DF,  p-value: < 2.2e-16
(summary(mod3.a) -> s3a)

##
## Call:
## lm(formula = price ~ sqft, data = br)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -366641  -31399   -1535    25601   932272
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -60861.462    6110.187   -9.961  <2e-16 ***
## sqft         92.747        2.411    38.476  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 79820 on 1078 degrees of freedom
## Multiple R-squared:  0.5786, Adjusted R-squared:  0.5783
## F-statistic: 1480 on 1 and 1078 DF,  p-value: < 2.2e-16
```

```
# desenhando os dados com as curvas de regressão
plot(br$sqft, br$price, pch = 20, col = "gray")
x = seq(min(br$sqft), max(br$sqft), length.out = 100)
y = predict(mod3, data.frame(sqft = x))
abline(mod3.a, col = "red", lwd = 2)
lines(x, y, col = "blue", lwd = 2)
legend("topleft", legend = c(bquote(paste("Primeiro grau: ",
  R[aj]^2 == .(s3a$adj.r.squared %>%
    round(4)))), bquote(paste("Segundo grau: ", R[aj]^2 ==
    .(s3$adj.r.squared %>%
    round(4)))), cex = 0.8, fill = c("red", "blue"))
grid()
```



```
b1 <- coef(mod3)[[1]]
b2 <- coef(mod3)[[2]]
sqftx = c(2000, 4000, 6000) #given values for sqft
pricex = b1 + b2 * sqftx^2 #prices corresponding to given sqft
DpriceDsqt <- 2 * b2 * sqftx # marginal effect of sqft on price
elasticity = DpriceDsqt * sqftx/pricex
b1
```

```
## [1] 55776.57
```

```
b2
```

```
## [1] 0.0154213
```


```
DpriceDsqt
```

```
## [1] 61.68521 123.37041 185.05562
```

```
elasticity #prints results
```


```
## [1] 1.050303 1.631251 1.817408
```

6.7.1 Verificando a variável dependente




Transformação de variáveis

```
hist(log(br$price))
```

Histogram of $\log(\text{br\$price})$ 

```
plot(br$sqft, log(br$price))
```



6.8 Using Indicator Variables in a Regression

Variável indicadora = dummy

$$dummy \in \{0, 1\}$$

utown = university town

```
data(utown)
head(utown)
```

price	sqft	age	utown	pool	fplace
205.452	23.46	6	0	0	1
185.328	20.03	5	0	0	1
248.422	27.77	6	0	0	0
154.690	20.17	1	0	0	0
221.801	26.45	0	0	0	1
199.119	21.56	6	0	0	1

```
mod5 = lm(price ~ utown, data = utown)
summary(mod5)
```

```
##
## Call:
## lm(formula = price ~ utown, data = utown)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -85.672 -20.359  -0.462   20.646   67.955
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   215.732      1.318   163.67  <2e-16 ***
## utown          61.509      1.830    33.62  <2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 28.91 on 998 degrees of freedom
## Multiple R-squared:  0.5311, Adjusted R-squared:  0.5306
## F-statistic: 1130 on 1 and 998 DF, p-value: < 2.2e-16
```

Fora de utown preço = 215.732 (215.7324948)

Dentro de utown preço = 215.7324948 + 61.5091064 = 277.2416012

```
mean(utown[utown$utown == 1, "price"])
```

```
## [1] 277.2416
```

```
mean(utown[utown$utown == 0, "price"])
```

```
## [1] 215.7325
```

```
library(magrittr)
utown[utown$utown == 1, "price"] %>%
  mean
```

```
## [1] 277.2416
utown[utown$utown == 0, "price"] %>%
  mean
## [1] 215.7325
```

6.9 Monte Carlo

Vamos ver depois

Capítulo 7

Chapter 3 Interval Estimation and Hypothesis Testing

7.1 Example: Confidence Intervals in the food Model

```
library(PoEdata)
data("food")
alpha <- 0.05 # chosen significance level
mod1 <- lm(food_exp ~ income, data = food)
b2 <- coef(mod1)[[2]]
df <- df.residual(mod1) # degrees of freedom
smod1 <- summary(mod1)
seb2 <- coef(smod1)[2, 2] # se(b2)
tc <- qt(1 - alpha/2, df)
lowb <- b2 - tc * seb2 # lower bound
upb <- b2 + tc * seb2 # upper bound
c(lowb, b2, upb)
```

```
## [1] 5.972052 10.209643 14.447233
```

Tenho 1-significância = $1 - 0.05 = 0.95 = 95\%$ de CONFIANÇA que o valor do coeficiente angular está situado entre 5.9720525 e 14.4472334.

```
confint(mod1, level = 0.95)
```

	2.5 %	97.5 %
(Intercept)	-4.463279	171.29528
income	5.972053	14.44723

7.2 Bootstrap

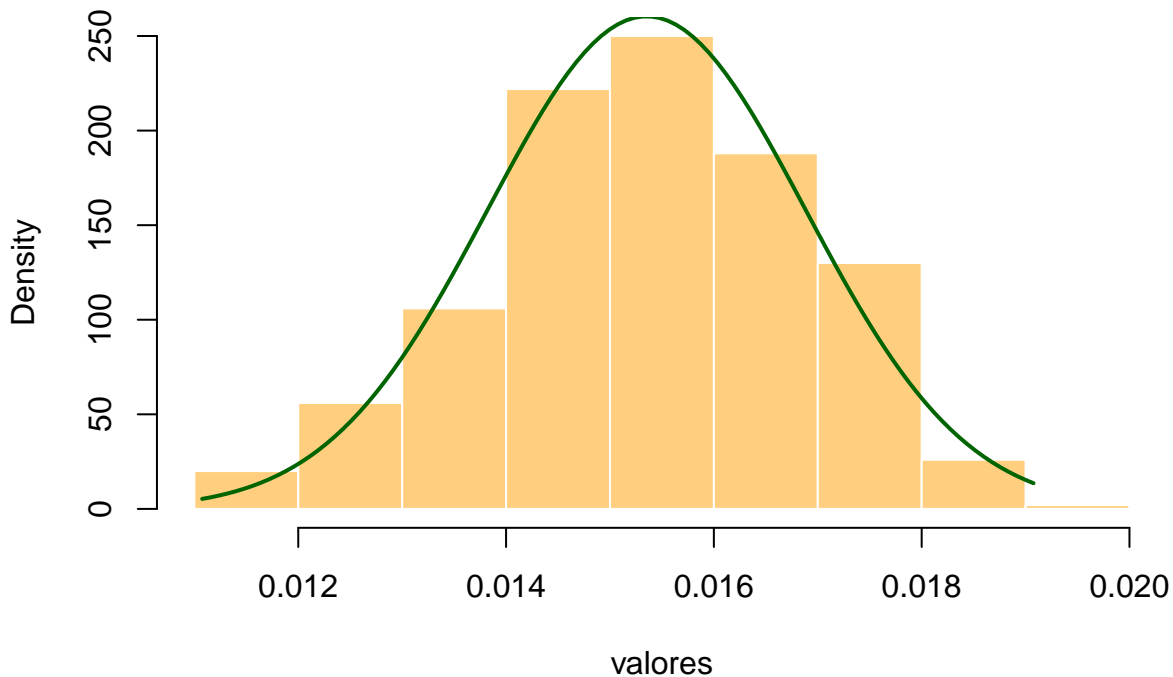
Reamostragem

```
# Trava o gerador de números pseudo-aleatórios
set.seed(1)
# Número de simulações
N = 500 # coloquei 500 para rodar mais rápido, na prática usa-se 2000 ou mais
# Número de elementos na amostra
```

```
nrow(br) -> n
# Inicializo vetor de valores
valores = NULL
# loop de reamostragem
for (i in 1:N) {
  # crio amostra de tamanho n com repetição
  sample(1:n, n, replace = TRUE) -> idx
  # faço a regressão
  lm(price ~ I(sqft^2), data = br[idx, ]) -> modb
  # guardo o valor do coeficiente angular
  valores = c(valores, modb$coefficients[2])
}

# desenho um histograma com uma curva normal superimposta
# Este esquema de cores é somente um exemplo, adote um
# padrão para todos os gráficos para não ficar um
# 'carnaval'
hist(valores, freq = FALSE, col = "#FFA000", border = "white")
curve(dnorm(x, mean(valores), sd(valores)), xlim = c(min(valores),
  max(valores)), add = TRUE, col = "darkgreen", lwd = 2)
```

Histogram of valores



```
c(mod3$coefficients[2], mean(valores))

## I(sqft^2)
## 0.01542130 0.01535264

# Teste de normalidade (veremos em um futuro próximo)
shapiro.test(sample(valores, min(500, length(valores))))

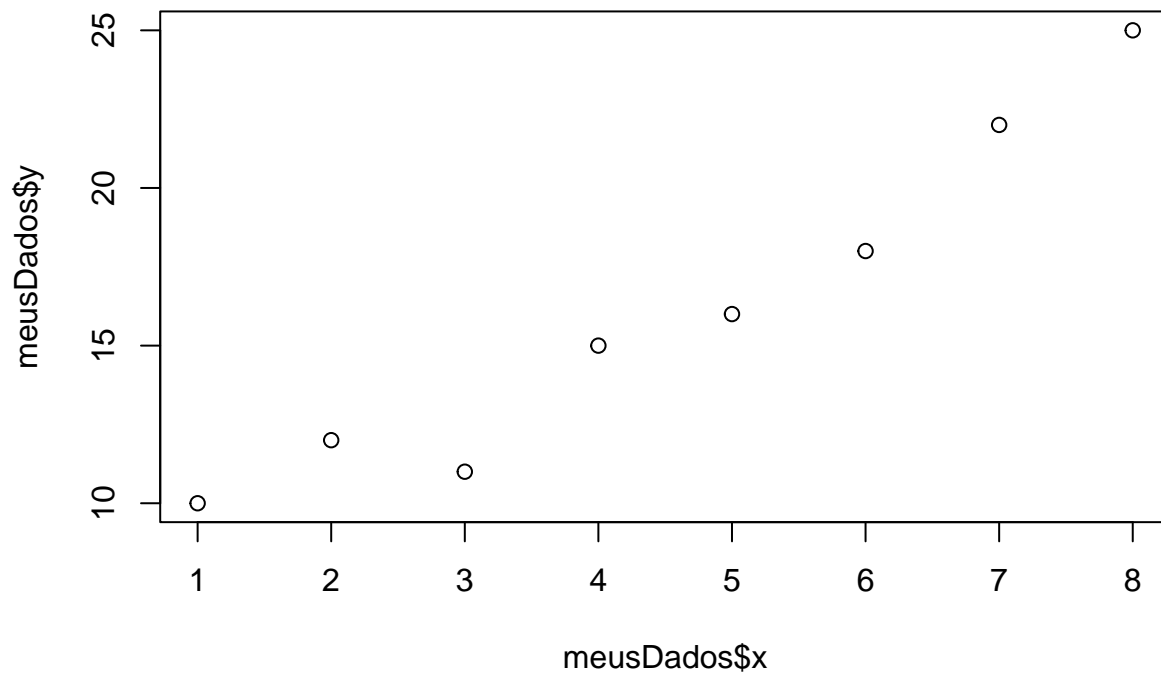
##
## Shapiro-Wilk normality test
```

```
##  
## data:  sample(valores, min(500, length(valores)))  
## W = 0.99399, p-value = 0.04537
```


Capítulo 8

Adendo - ler dados do EXCEL

```
# file.choose()
library(openxlsx)
read.xlsx("/Users/jfrega/Downloads/DadosTeste.xlsx", sheet = "Planilha1",
  startRow = 1) -> meusDados
plot(meusDados$x, meusDados$y)
```



```
lm(y ~ x, meusDados) -> m
m %>%
  summary
```

```
##
## Call:
## lm(formula = y ~ x, data = meusDados)
##
## Residuals:
```

##	Min	1Q	Median	3Q	Max
----	-----	----	--------	----	-----

```
## -1.9643 -1.2054 0.2679 1.1696 1.5000
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept)  6.6429      1.1198   5.932 0.00102 **
## x            2.1071      0.2218   9.502 7.75e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 1.437 on 6 degrees of freedom
## Multiple R-squared:  0.9377, Adjusted R-squared:  0.9273
## F-statistic: 90.29 on 1 and 6 DF, p-value: 7.745e-05
```


Capítulo 9

Adendo — Regressão OLS em Python

```
#““
#
# ATENÇÃO: para rodar este trecho do código é necessário ter o Python instalado e configurado
#
# o comando import do Python é similar ao comando library do R
# statsmodels.formula.api é a interface para os modelos estatísticos
import statsmodels.formula.api as smf
# vou acessar os dados que foram lidos no meu código em R
r.meusDados

##      x      y
## 0  1.0  10.0
## 1  2.0  12.0
## 2  3.0  11.0
## 3  4.0  15.0
## 4  5.0  16.0
## 5  6.0  18.0
## 6  7.0  22.0
## 7  8.0  25.0

# rodo o modelo OLS
model = smf.ols(formula="y~x", data=r.meusDados)
# inspeciono os resultados
print(model.fit().summary())

##                                OLS Regression Results
## =====
## Dep. Variable:                  y      R-squared:                0.938
## Model:                        OLS      Adj. R-squared:          0.927
## Method:                     Least Squares      F-statistic:           90.29
## Date:                       Tue, 25 Mar 2025      Prob (F-statistic):       7.75e-05
## Time:                       16:22:12      Log-Likelihood:          -13.102
## No. Observations:              8      AIC:                     30.20
## Df Residuals:                  6      BIC:                     30.36
## Df Model:                      1
## Covariance Type:               nonrobust
## =====
##                                coef      std err          t      P>|t|      [0.025      0.975]
## -----
```

```

## Intercept      6.6429      1.120      5.932      0.001      3.903      9.383
## x              2.1071      0.222      9.502      0.000      1.565      2.650
## =====
## Omnibus:                2.183   Durbin-Watson:                1.522
## Prob(Omnibus):          0.336   Jarque-Bera (JB):          0.848
## Skew:                   -0.279   Prob(JB):                  0.654
## Kurtosis:               1.505   Cond. No.                  11.5
## =====
##
## Notes:
## [1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
##
## /Users/jfrega/Library/r-miniconda-arm64/lib/python3.10/site-packages/scipy/stats/_axis_nan_policy.py:41
##     return hypotest_fun_in(*args, **kwds)
##
## """

```